

# 机器学习纸质课程作业

## 一、证明题

- (1) 证明  $f(\omega) = \frac{1}{2} \|\omega\|^2$  是凸函数，即对  $\forall \omega_1, \omega_2, \forall \lambda \in [0, 1]$ ，都有
- $$f(\lambda\omega_1 + (1-\lambda)\omega_2) \leq \lambda f(\omega_1) + (1-\lambda)f(\omega_2)$$

证明：

目标不等式：

我们需要证明

$$\frac{1}{2} \|\lambda\omega_1 + (1-\lambda)\omega_2\|^2 \leq \lambda \cdot \frac{1}{2} \|\omega_1\|^2 + (1-\lambda) \cdot \frac{1}{2} \|\omega_2\|^2$$

两边同时乘以 2，等价于

$$\|\lambda\omega_1 + (1-\lambda)\omega_2\|^2 \leq \lambda \|\omega_1\|^2 + (1-\lambda) \|\omega_2\|^2$$

展开左边项：

令  $\omega = \lambda\omega_1 + (1-\lambda)\omega_2$ ，则

$$\|\omega\|^2 = \langle \omega, \omega \rangle = \langle \lambda\omega_1 + (1-\lambda)\omega_2, \lambda\omega_1 + (1-\lambda)\omega_2 \rangle$$

其中  $\langle \cdot, \cdot \rangle$  表示点积。展开点积：

$$\begin{aligned} \|\omega\|^2 &= \lambda^2 \langle \omega_1, \omega_1 \rangle + 2\lambda(1-\lambda) \langle \omega_1, \omega_2 \rangle + (1-\lambda)^2 \langle \omega_2, \omega_2 \rangle \\ &= \lambda^2 \|\omega_1\|^2 + 2\lambda(1-\lambda) \langle \omega_1, \omega_2 \rangle + (1-\lambda)^2 \|\omega_2\|^2 \end{aligned}$$

计算差值：

$$\lambda \|\omega_1\|^2 + (1-\lambda) \|\omega_2\|^2 - \|\lambda\omega_1 + (1-\lambda)\omega_2\|^2$$

代入展开式：

$$= \lambda \|\omega_1\|^2 + (1-\lambda) \|\omega_2\|^2 - [\lambda^2 \|\omega_1\|^2 + 2\lambda(1-\lambda) \langle \omega_1, \omega_2 \rangle + (1-\lambda)^2 \|\omega_2\|^2]$$

简化：

$$= (\lambda - \lambda^2) \|\omega_1\|^2 + [(1-\lambda) - (1-\lambda)^2] \|\omega_2\|^2 - 2\lambda(1-\lambda) \langle \omega_1, \omega_2 \rangle$$

注意  $\lambda - \lambda^2 = \lambda(1-\lambda)$  和  $(1-\lambda) - (1-\lambda)^2 = (1-\lambda)[1 - (1-\lambda)] = (1-\lambda)\lambda = \lambda(1-\lambda)$ ，所以：

$$\begin{aligned} &= \lambda(1-\lambda) \|\omega_1\|^2 + \lambda(1-\lambda) \|\omega_2\|^2 - 2\lambda(1-\lambda) \langle \omega_1, \omega_2 \rangle \\ &= \lambda(1-\lambda) [\|\omega_1\|^2 + \|\omega_2\|^2 - 2\langle \omega_1, \omega_2 \rangle] \end{aligned}$$

括号中的项为  $\|\omega_1 - \omega_2\|^2$ ：

$$= \lambda(1-\lambda) \|\omega_1 - \omega_2\|^2$$

分析差值：

由于  $\lambda \in [0, 1]$ ，有  $\lambda(1-\lambda) \geq 0$ ，且  $\|\omega_1 - \omega_2\|^2 \geq 0$ （范数平方非负），因此

$$\lambda(1-\lambda) \|\omega_1 - \omega_2\|^2 \geq 0$$

这意味着

$$\lambda \|\omega_1\|^2 + (1-\lambda) \|\omega_2\|^2 - \|\lambda\omega_1 + (1-\lambda)\omega_2\|^2 \geq 0$$

即

$$\|\lambda\omega_1 + (1-\lambda)\omega_2\|^2 \leq \lambda \|\omega_1\|^2 + (1-\lambda) \|\omega_2\|^2$$

回到函数  $f$ :

将上述不等式乘以  $\frac{1}{2}$ , 得到

$$\frac{1}{2} \|\lambda\omega_1 + (1-\lambda)\omega_2\|^2 \leq \frac{1}{2} [\lambda \|\omega_1\|^2 + (1-\lambda) \|\omega_2\|^2] = \lambda \cdot \frac{1}{2} \|\omega_1\|^2 + (1-\lambda) \cdot \frac{1}{2} \|\omega_2\|^2$$

也就是

$$f(\lambda\omega_1 + (1-\lambda)\omega_2) \leq \lambda f(\omega_1) + (1-\lambda)f(\omega_2)$$

结论:

因此, 函数  $f(\omega) = \frac{1}{2} \|\omega\|^2$  满足凸函数的定义, 是凸函数。

(2) 证明两个凸函数的和仍然是凸函数, 因此支持向量机的目标函数

$$\frac{1}{2} \|\omega\|^2 + c \sum_{i=1}^N \delta_i$$

是凸函数。

证明一: 两个凸函数之和是凸的

设  $f$  与  $g$  在同一凸集  $D$  上凸。取任意  $x, y \in D$  与任意  $\lambda \in [0, 1]$ 。由凸性分别有

$$\begin{aligned} f(\lambda x + (1-\lambda)y) &\leq \lambda f(x) + (1-\lambda)f(y), \\ g(\lambda x + (1-\lambda)y) &\leq \lambda g(x) + (1-\lambda)g(y). \end{aligned}$$

对两式逐项相加得到

$$f(\lambda x + (1-\lambda)y) + g(\lambda x + (1-\lambda)y) \leq \lambda(f(x) + g(x)) + (1-\lambda)(f(y) + g(y)).$$

即

$$h(\lambda x + (1-\lambda)y) \leq \lambda h(x) + (1-\lambda)h(y),$$

因此  $h = f + g$  在  $D$  上凸。

证明二: 正标量乘保凸性

若  $f$  凸且  $C \geq 0$ , 则对所有  $x, y \in D, \lambda \in [0, 1]$ :

$$Cf(\lambda x + (1 - \lambda)y) \leq C(\lambda f(x) + (1 - \lambda)f(y)) = \lambda(Cf(x)) + (1 - \lambda)(Cf(y)),$$

所以  $Cf$  也凸 (若  $C < 0$  则会反向, 不再保持凸性)。

综上

$$\frac{1}{2}\|\omega\|^2 + C \sum_{i=1}^N \delta_i$$

是凸函数。

(3) 请证明:  $\theta(\alpha, \beta)$  是一个凹函数, 即对任意  $(\alpha_1, \beta_1, \alpha_2, \beta_2)$ ,  $\lambda \in [0, 1]$ , 有:

$$\theta(\lambda\alpha_1 + (1 - \lambda)\alpha_2, \lambda\beta_1 + (1 - \lambda)\beta_2) \geq \lambda\theta(\alpha_1, \beta_1) + (1 - \lambda)\theta(\alpha_2, \beta_2)$$

(提示, 请先证明:  $\inf_{\omega \in \Omega} [a(\omega) + b(\omega)] \geq \inf_{\omega \in \Omega} [a(\omega)] + \inf_{\omega \in \Omega} [b(\omega)]$ )

应用该定理可以直接得到支持向量机对偶问题的目标函数

$$\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

是凹函数, 因此最大化此目标函数有唯一解。

1) 先证明提示的不等式

令  $a(\omega)$  与  $b(\omega)$  为定义在同一集合  $\Omega$  上的任意实值函数。我们要证

$$\inf_{\omega \in \Omega} [a(\omega) + b(\omega)] \geq \inf_{\omega \in \Omega} a(\omega) + \inf_{\omega \in \Omega} b(\omega).$$

证明: 对任意固定的  $\omega \in \Omega$ , 都有

$a(\omega) \geq \inf_{\tilde{\omega}} a(\tilde{\omega})$  且  $b(\omega) \geq \inf_{\tilde{\omega}} b(\tilde{\omega})$ 。因此

$$a(\omega) + b(\omega) \geq \inf_{\tilde{\omega}} a(\tilde{\omega}) + \inf_{\tilde{\omega}} b(\tilde{\omega}).$$

对所有  $\omega$  求下确界时, 左边的下确界不会小于右边的常数, 即

$$\inf_{\omega} [a(\omega) + b(\omega)] \geq \inf_{\tilde{\omega}} a(\tilde{\omega}) + \inf_{\tilde{\omega}} b(\tilde{\omega}).$$

证毕。

2) 证明  $\theta(\alpha, \beta) = \inf_{\omega \in \Omega} L(\omega, \alpha, \beta)$  是凹函数

回忆拉格朗日函数的形式 (对任意固定  $\omega$ ):

$$L(\omega, \alpha, \beta) = f(\omega) + \alpha^T g(\omega) + \beta^T h(\omega).$$

对于固定的  $\omega$ ,  $L(\omega, \alpha, \beta)$  是关于  $(\alpha, \beta)$  的仿射函数 (即线性加常数)。仿射函数既是凸的也是凹的; 对任意两组乘子  $(\alpha_1, \beta_1)$  与  $(\alpha_2, \beta_2)$  和任意  $\lambda \in [0, 1]$ ,

$$L(\omega, \lambda(\alpha_1, \beta_1) + (1 - \lambda)(\alpha_2, \beta_2)) = \lambda L(\omega, \alpha_1, \beta_1) + (1 - \lambda)L(\omega, \alpha_2, \beta_2).$$

因此

$$\begin{aligned} \theta(\lambda(\alpha_1, \beta_1) + (1 - \lambda)(\alpha_2, \beta_2)) &= \inf_{\omega \in \Omega} L(\omega, \lambda(\alpha_1, \beta_1) + (1 - \lambda)(\alpha_2, \beta_2)) \\ &= \inf_{\omega \in \Omega} [\lambda L(\omega, \alpha_1, \beta_1) + (1 - \lambda)L(\omega, \alpha_2, \beta_2)]. \end{aligned}$$

用第 1) 节的推广结论 (对带系数的线性组合取  $\inf$  的不等式), 我们得到

$$\inf_{\omega} [\lambda L(\omega, \alpha_1, \beta_1) + (1 - \lambda)L(\omega, \alpha_2, \beta_2)] \geq \lambda \inf_{\omega} L(\omega, \alpha_1, \beta_1) + (1 - \lambda) \inf_{\omega} L(\omega, \alpha_2, \beta_2).$$

也就是

$$\theta(\lambda(\alpha_1, \beta_1) + (1 - \lambda)(\alpha_2, \beta_2)) \geq \lambda \theta(\alpha_1, \beta_1) + (1 - \lambda) \theta(\alpha_2, \beta_2).$$

这正是  $\theta$  关于  $(\alpha, \beta)$  的凹性定义。证毕。

### 3) 应用到支持向量机对偶问题

在支持向量机的对偶问题中, 目标函数为:

$$\sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

这个函数可以看作是一个特殊的  $\theta(\alpha)$  函数 (没有  $\beta$  参数), 其中:

- 线性项  $\sum_{i=1}^N \alpha_i$  对应  $f(\omega)$  部分
- 二次型  $-\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$  对应约束部分

由于:

- (1) 线性函数  $\sum_{i=1}^N \alpha_i$  是凸的也是凹的;
- (2) 二次型  $-\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$  是凹函数 (因为核矩阵  $K(x_i, x_j)$  是半正定的, 其负二次型是凹的);
- (3) 凹函数的和仍然是凹函数。

因此, 整个目标函数是凹函数。

由于目标函数是凹函数且约束条件是线性的, 这个最大化问题是一个凸优化问题, 有唯一全局最优解。

**结论：**我们证明了  $\theta(\alpha, \beta)$  是凹函数，并应用这个结论说明了支持向量机对偶问题的目标函数是凹函数，因此最大化此目标函数有唯一解。

#### (4) 选做题

##### (a) 在二维特征空间中不存在能被线性分类器“打散”的 4 个点

**证明：**

1. 我们先排除退化情形（有三点共线等）——若有三点共线，更容易找出不可分的标记（例如把共线的一端标为 +，另一端标为 -，中间点同一侧等），因此只需论证一般位置（无三点共线）的情况即可；随机取点时一般位置的情况以概率 1 发生。
2. 对无三点共线的四点，凸包要么是一个四边形（四点位于凸位置，即四个顶点按环形排列），要么是一个三角形（其中一个点落在其余三点构成的三角形内部）。
  - 若凸包是三角形（即有一个点在其它三个点的凸包内部），记内部点为  $p$ ，其余三个为  $a, b, c$ 。把  $p$  标为 +1，而把  $a, b, c$  都标为 -1（三者同号），任何将  $p$  与  $a, b, c$  分开的半空间（由直线给出）都必须把包含  $a, b, c$  的半空间与包含  $p$  的半空间分开。但因为  $p$  在  $a, b, c$  的凸包内部，任何包含  $a, b, c$  的凸半空间的凸包必然也包含  $p$  因而不可能有单一的半空间把  $p$  与  $a, b, c$  分开。由此该标记不可分。
  - 若凸包是凸四边形（四点按环形排列无内点），将四点按环形编号为  $v_1, v_2, v_3, v_4$ 。考虑“交替标记”：给  $v_1, v_3$  标为 +1，给  $v_2, v_4$  标为 -1（或者相反）。任何半空间与凸四边形交集的顶点集合在环形上必是连通的区间（半空间切割多边形后留下的顶点是相邻的一段），因此不可能得到交替出现的模式（+、-、+、-）。更形式地：对任意直线，四边形顶点被分到直线两侧时，同一侧的顶点在原多边形循环序列上形成一个连块；交替标记要求同号顶点不成连块，故无法用一条直线实现。因此交替标记不可分。

两个情况已覆盖所有无退化的四点布置，故对任意 4 点总能找到不可分的标签组合，因此平面线性分类器不能“打散”任意 4 点。证毕。

（因此平面线性分类器的 VC 维为 3——存在某些 3 点可被打散，且不存在任意 4 点被打散。）

##### (b) 在线性分类器（超平面 $\omega^T x + b = 0$ ）下， $\mathbb{R}^d$ 的 VC 维为 $d + 1$

要证两件事：

- (i) 存在  $d + 1$  个点能被线性分类器打散；
- (ii) 任意  $d + 2$  个点不能被线性分类器打散（即  $VC \leq d + 1$ ）。可得  $VC = d + 1$ 。

##### (i) 构造能被打散的 $d + 1$ 个点

取任意  $d + 1$  个仿射无关的点  $x_1, \dots, x_{d+1} \in \mathbb{R}^d$ 。仿射无关意味着这些点的增广矩阵

$$\begin{pmatrix} x_1^T & 1 \\ x_2^T & 1 \\ \vdots & \vdots \\ x_{d+1}^T & 1 \end{pmatrix}$$

是一个  $(d+1) \times (d+1)$  的可逆矩阵。现在给任意二分类标签  $y_i \in \{+1, -1\}$  (共  $2^{d+1}$  种), 我们要找  $(\omega, b) \in \mathbb{R}^d \times \mathbb{R}$  使得

$$\text{sign}(\omega^\top x_i + b) = y_i, i = 1, \dots, d+1.$$

更强地, 我们可以要求确切地拟合实数值 (不仅仅是符号), 例如解线性方程组

$$\omega^\top x_i + b = y_i, i = 1, \dots, d+1.$$

这是  $d+1$  个线性方程、 $d+1$  个未知数 ( $\omega$  的  $d$  个分量和标量  $b$ ), 系数矩阵就是上面的增广矩阵的转置, 因仿射无关而可逆, 因此方程组有唯一解。求得的  $(\omega, b)$  使得  $\omega^\top x_i + b = y_i$  (严格等于  $\pm 1$ ), 于是符号完全匹配任意给定的  $y_i$ 。因此任意标签都能被正确分类, 说明这  $d+1$  个点被打散。故  $VC \geq d+1$ 。

## (ii) 任意 $d+2$ 个点不能被打散 ( $VC \leq d+1$ )

任意  $d+2$  个点在  $\mathbb{R}^d$  中必有仿射依赖 (因为维数为  $d$ , 任何  $d+2$  个点线性/仿射相关)。由 **Radon 定理**: 任意  $d+2$  个点可以被划分为两组  $A$  与  $B$  (互不相交), 使得这两组点的凸包相交, 即  $\text{conv}(A) \cap \text{conv}(B) \neq \emptyset$ 。

现在取这种 Radon 划分, 并把  $A$  的点全部标为  $+1$ , 把  $B$  的点全部标为  $-1$ 。若存在一个超平面把  $+1$  与  $-1$  完全分开, 则正类 ( $+1$  点) 的半空间是一个凸集, 且包含  $A$  的所有点; 因此它也应包含  $\text{conv}(A)$ 。类似, 负类的半空间包含  $\text{conv}(B)$ 。但因为这两凸包有交点, 任何将两个凸包严格分开的超平面都不存在 (两个凸包相交表示不能通过超平面把它们分离成不同的开半空间)。因此该标记不可被超平面分离。由此任意  $d+2$  个点总存在一种标记不可分, 故不能被打散, 得  $VC \leq d+1$ 。

结合 (i)、(ii) 得  $VC = d+1$ 。证毕。

## (c) 由 (b) 推出 $\lim_{d \rightarrow \infty} P(d, N) = 1$

明确题意:

- 在固定的样本数  $N$  下, 随机从  $\mathbb{R}^d$  中取  $N$  个点 (例如从连续分布独立同分布抽取), 并对这  $N$  个点随机标记  $+1/-1$  (独立均匀), 问: 随着维度  $d$  增大, 点集被线性分类器线性可分 (即存在一个超平面把正负两类完全分开) 的概率  $P(d, N)$  的极限。

证明要点:

- 若  $N \leq d+1$ , 并且点为一般位置 (概率 1 情形: 从连续分布随机取点, 任意  $k \leq d+1$  个点几乎肯定仿射无关), 则这些点仿射无关, 从 (b) 我们知道对任意标签都存在一个超平面精确拟合 (解线性方程组), 因而任意标签组合均线性可分  $\rightarrow$  对于这种点的具体位置, 任意标签下都可分。因此当  $d \geq N-1$  时, 随机取的  $N$  个点几乎必是仿射无关, 从而对于任意标签都线性可分, 故此时  $P(d, N) = 1$  (严格来说为 1 在概率意义上: 除去测度为 0 的退化点集)。
- 因此当  $d \rightarrow \infty$  (固定  $N$ ), 存在某个阈值  $d_0 = N-1$  使得对所有  $d \geq d_0$  有  $P(d, N) = 1$ 。所以

$$\lim_{d \rightarrow \infty} P(d, N) = 1.$$

更直观地：当维度远大于样本数时，样本点几乎总是处于仿射无关的位置（没有线性/仿射关系），从而在  $d$  维空间中总能找到一个超平面来实现任意的分配；因此随机标记几乎总被线性分隔。

## 二、 请写出以下问题的对偶问题，并化成最简形式

### (1) $l_2$ -norm SVM Classification

原问题：

$$\begin{aligned} \min_{\omega, b, \delta} \quad & \frac{1}{2} \|\omega\|^2 + C \sum_{i=1}^N \delta_i^2 \\ \text{s.t.} \quad & y_i(\omega^T \phi(x_i) + b) \geq 1 - \delta_i, \\ & \delta_i \geq 0 \end{aligned}$$

对偶问题：

引入拉格朗日乘子  $\alpha_i \geq 0$  对应于约束  $y_i(\omega^T \phi(x_i) + b) \geq 1 - \delta_i$ 。

拉格朗日函数：

$$L = \frac{1}{2} \|\omega\|^2 + C \sum_i \delta_i^2 - \sum_i \alpha_i [y_i(\omega^T \phi(x_i) + b) - 1 + \delta_i]$$

消去原变量  $\omega, b, \delta_i$ ：

$$\omega = \sum_i \alpha_i y_i \phi(x_i), \sum_i \alpha_i y_i = 0, \delta_i = \frac{\alpha_i}{2C}$$

代回得：

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \frac{1}{4C} \sum_{i=1}^N \alpha_i^2 \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0, \alpha_i \geq 0 \end{aligned}$$

这是  $l_2$ -SVM 的最简对偶形式。

### (2) SVM Regression (选做)

原问题：

$$\begin{aligned} \min_{\omega, b, \delta, \zeta} \quad & \frac{1}{2} \|\omega\|^2 + C \sum_i (\delta_i + \zeta_i) \\ \text{s.t.} \quad & \omega^T \phi(x_i) + b - y_i \leq \varepsilon + \delta_i, \\ & y_i - \omega^T \phi(x_i) - b \leq \varepsilon + \zeta_i, \\ & \delta_i, \zeta_i \geq 0 \end{aligned}$$

对偶问题

最大化 (Maximize)：

$$\theta(\alpha, \beta, u, v) = \sum_{i=1}^N (\beta_i - \alpha_i) y_i - \left[ \sum_{i=1}^N (\alpha_i + \beta_i) \right] \varepsilon - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N (\beta_i - \alpha_i) (\beta_j - \alpha_j) K(X_i, X_j)$$

限制条件(Subject to): ①  $0 \leq \alpha_i \leq C$

②  $0 \leq \beta_i \leq C$

③  $\sum_{i=1}^N \alpha_i = \sum_{i=1}^N \beta_i$

### (3) Kernel Ridge Regression

原问题:

$$\begin{aligned} \min_{\omega, \delta} \quad & \frac{1}{2} \|\omega\|^2 + C \sum_i \delta_i^2 \\ \text{s.t.} \quad & y_i - \omega^T \phi(x_i) = \delta_i \end{aligned}$$

对偶问题:

拉格朗日函数, 令  $\alpha_i$  为约束乘子:

$$L = \frac{1}{2} \|\omega\|^2 + C \sum_i \delta_i^2 + \sum_i \alpha_i (y_i - \omega^T \phi(x_i) - \delta_i)$$

求偏导:

$$\omega = \sum_i \alpha_i \phi(x_i), \delta_i = \frac{\alpha_i}{2C}$$

代回:

$$\max_{\alpha} \sum_i \alpha_i y_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j K(x_i, x_j) - \frac{1}{4C} \sum_i \alpha_i^2$$

无约束对偶形式 (线性方程形式):

$$(K + \frac{1}{2C} I) \alpha = y$$

从而  $\omega = \sum_i \alpha_i \phi(x_i)$ 。

### (4) Entropy Maximization Problem

原问题:

$$\begin{aligned} \min_x \quad & \sum_i x_i \log x_i \\ \text{s.t.} \quad & \omega^T x \leq b, \\ & \sum_i x_i = 1 \end{aligned}$$

对偶问题:

拉格朗日函数:

$$L(x, \lambda, v) = \sum_i x_i \log x_i + \lambda (\omega^T x - b) + v (\sum_i x_i - 1)$$



对  $x_i$  求导并设为 0:

$$1 + \log x_i + \lambda \omega_i + v = 0 \Rightarrow x_i = e^{-1-v-\lambda \omega_i}$$

代回原约束  $\sum_i x_i = 1$ :

$$e^{-1-v} \sum_i e^{-\lambda \omega_i} = 1 \Rightarrow e^{-1-v} = \frac{1}{\sum_i e^{-\lambda \omega_i}}$$

代回目标函数得对偶形式:

$$\max_{\lambda \geq 0} -\lambda b - \log \left( \sum_i e^{-\lambda \omega_i} \right)$$

### 三、 包含点集的最小球问题

对偶推导

对第  $i$  个不等式引入拉格朗日乘子  $\alpha_i \geq 0$ , 对  $\xi_i \geq 0$  引入  $\mu_i \geq 0$ 。拉格朗日函数:

$$L(R, C, \xi, \alpha, \mu) = R^2 + B \sum_i \xi_i + \sum_i \alpha_i (\|x_i - C\|^2 - R^2 - \xi_i) - \sum_i \mu_i \xi_i.$$

驻点条件 (对  $R, C, \xi_i$  求偏导并令零) 给出

$$\begin{aligned} \partial_R: 2R(1 - \sum_i \alpha_i) &= 0 \Rightarrow \sum_i \alpha_i = 1, \\ \partial_C: -2 \sum_i \alpha_i (x_i - C) &= 0 \Rightarrow C = \sum_i \alpha_i x_i, \\ \partial_{\xi_i}: B - \alpha_i - \mu_i &= 0 \Rightarrow 0 \leq \alpha_i \leq B. \end{aligned}$$

把  $C = \sum_j \alpha_j x_j$  代回  $L$  并消去其他项 ( $R$  项为零), 得到对偶目标:

$$\begin{aligned} g(\alpha) &= \sum_{i=1}^N \alpha_i \|x_i\|^2 - \left\| \sum_{i=1}^N \alpha_i x_i \right\|^2 \\ &= \sum_{i=1}^N \alpha_i \|x_i\|^2 - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j x_i^\top x_j. \end{aligned}$$

#### (1) 对偶问题 (最简形式)

$$\begin{aligned} &\max_{\alpha \in \mathbb{R}^N} \sum_{i=1}^N \alpha_i \|x_i\|^2 - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j x_i^\top x_j \\ \text{s.t. } &\sum_{i=1}^N \alpha_i = 1, 0 \leq \alpha_i \leq B \quad (i = 1, \dots, N). \end{aligned}$$

(这是一个带线性约束与简单界的二次凸规划问题。)

(2) 核化 (取  $K(x_i, x_j) = x_i^\top x_j$  或一般核)

将内积替换为核函数  $K$ , 对偶写成核矩阵形式:

$$\begin{array}{ll} \max_{\alpha} & \sum_{i=1}^N \alpha_i K(x_i, x_i) - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j K(x_i, x_j) \\ \text{s.t.} & \sum_{i=1}^N \alpha_i = 1, 0 \leq \alpha_i \leq B. \end{array}$$

用向量 / 矩阵记号 (令  $K$  为核矩阵,  $d = [K_{11}, \dots, K_{NN}]^\top$ ,  $\alpha$  为系数向量), 目标可写为

$$\max_{\alpha} \alpha^\top d - \alpha^\top K \alpha \quad \text{s.t.} \quad \mathbf{1}^\top \alpha = 1, 0 \leq \alpha \leq B \mathbf{1}.$$

(3) 用核表示  $R$

若索引  $s$  满足  $0 < \alpha_s < B$  (即对应约束为等号的“支撑点”), 则由 KKT 有

$\|x_s - C\|^2 = R^2$ 。用  $C = \sum_j \alpha_j x_j$  展开, 得

$$\begin{aligned} R^2 &= \|x_s\|^2 - 2 \sum_{j=1}^N \alpha_j x_s^\top x_j + \sum_{j=1}^N \sum_{k=1}^N \alpha_j \alpha_k x_j^\top x_k \\ &= K(x_s, x_s) - 2 \sum_{j=1}^N \alpha_j K(x_s, x_j) + \sum_{j=1}^N \sum_{k=1}^N \alpha_j \alpha_k K(x_j, x_k). \end{aligned}$$

因此  $R$  的核形式为

$$R = \sqrt{K(x_s, x_s) - 2 \sum_j \alpha_j K(x_s, x_j) + \sum_{j,k} \alpha_j \alpha_k K(x_j, x_k)}$$

(任取一个  $s$  使  $0 < \alpha_s < B$ ; 若有多个支撑点, 任一支撑点代入均应给出相同的  $R^2$ )。